

Türkçe Kurumsal E-Postalarda Etik Dışı Dil Tespiti

01.09.2026 17:17:15

1/14 Türkçe Kurumsal E-Postalarda Etik Dışı Dil Tespiti

Merhaba, bugün sizlere Türkçe kurumsal e-postalarda etik dışı dil kullanımının yapay zekâ ile otomatik olarak tespit edilmesine yönelik gerçekleştirdiğimiz çalışmayı sunacağım.

Çalışmamızda özellikle kurumsal iletişimde karşımıza çıkabilen pasif-agresif, küçümseyici, baskılayıcı ve benzeri etik dışı dil örüntülerine odaklandık.

2/14

Etik dışı dil dediğimizde genellikle aklımıza hakaret, küfür, nefret söylemi veya açık saldırganlık geliyor.

Fakat kurumsal iletişimde problem her zaman bu kadar açık değil.

Örneğin burada doğrudan bir hakaret bulunmuyor. Ancak kullanılan dil baskılayıcı ve pasif-agresif bir iletişim biçimi oluşturabiliyor.



1 Pasif-agresif, baskılayıcı, küçümseyici — bunlar hakaret gibi sözlükte aranan kelimeler değil.



2 Dolayısıyla problem yalnızca kötü kelimeleri tespit etmek değil; iletişim biçimini ve bağlamı anlayabilmek.

3/14 Neden Kurumsal E-Posta?

Dijitalleşmeyle birlikte kurum içi iletişim de önemli ölçüde dijital kanallara taşındı.

1 Özellikle e-posta gibi yazılı iletişim kanallarında tonlama ve beden dili gibi bağlam sağlayan unsurlar ortadan kalktığı için, mesajın nasıl algılandığı daha kritik hâle geliyor.

2 Bu nedenle kurumsal iletişimde etik dışı dilin tespiti, yalnızca bir NLP problemi değil, aynı zamanda çalışma ortamının iletişim kalitesiyle ilişkili bir problem.

4/14 Literatürdeki Boşluk

Literatürü incelediğimizde burada iki farklı eğilim görüyoruz.

Bir tarafta sosyal medya ve çevrim içi platformlarda toksik, saldırgan ve hakaret içeren dilin tespitine yönelik çalışmalar var.

Diğer tarafta kurumsal e-postalar üzerinde NLP çalışmaları bulunuyor; ancak bunların önemli bir bölümü dolandırıcılık, phishing veya insider threat gibi güvenlik problemlerine odaklanıyor.

1 Bizim çalışmamız ise bu ikisinin arasında kalan, ancak doğrudan hedeflenmemiş bir probleme odaklanıyor: kurum içerisindeki gündelik etik dışı iletişim.

2 Yani bizim sorumuz "Bu e-posta dolandırıcılık mı?" değil; "Bu e-posta çalışanlar arası etik iletişime uygun mu?"

5/14 Biz Ne Yaptık?

Bu boşluğu ele almak amacıyla Türkçe kurumsal iletişime özgü bir veri seti oluşturduk.

1 Bu veri seti üzerinde önceden eğitilmiş BERTürk modelini fine-tune ederek ikili bir etik dil sınıflandırıcısı geliştirdik.

2 Son aşamada da modeli çalışan bir web tabanlı prototip sisteme entegre ettik.

6/14 Veri Seti

Çalışmanın önemli bileşenlerinden biri probleme özgü veri setimiz.

- 1 Toplam 3.222 benzersiz Türkçe kurumsal iletişim metni oluşturduk ve bunları etik ve etik dışı olmak üzere iki sınıfa ayırdık. Dengeli bir dağılım oluşturulmasına özen gösterildi.
- 2 Etik dışı örneklerde hiyerarşik baskı, küçümseyici ifadeler, pasif-agresif söylemler, tehditkâr dil ve mobbing niteliği taşıyan iletişim biçimlerini temsil etmeyi hedefledik.

7/14 Veriyi Nasıl Güvenilir Hale Getirdik?

Burada özellikle veri setinin oluşturulma sürecini vurgulamak istiyoruz.

- 1 Metinlerin oluşturulmasında Claude ve ChatGPT gibi büyük dil modellerinden yararlandık; ancak oluşturulan içerikleri doğrudan veri setine aktarmadık.
- 2 Her metin araştırmacılar tarafından tek tek incelendi. Metnin kurumsal bağlama uygunluğu, doğal ve gerçekçi olması, anlamsal tutarlılığı ve daha önce kullanılan bir örnekle birebir aynı olmaması kontrol edildi. Sonrasında tüm örnekler yine insan gözetiminde etik veya etik dışı olarak etiketlendi.
- 3 Dolayısıyla model, BDM'nin verdiği etikete doğrudan eğitilmedi. Üretim ile kabul arasında her zaman bir insan denetimi katmanı vardı.

8/14 Neden BERTürk?

Model tarafında ise BERTürk'ü tercih ettik.

- 1 BERTürk, Türkçe için önceden eğitilmiş bir BERT modelidir ve çalışmamızda kurumsal iletişim metinlerinin etik veya etik dışı olarak sınıflandırılması için fine-tune edilmiştir.
- 2 Buradaki önemli nokta, modelin yalnızca belirli kelimeleri aramak yerine metni bağlamsal olarak temsil etmesidir.

9/14 Eğitim → Değerlendirme

Model eğitim ve doğrulama sürecinden geçirildikten sonra, performansını eğitim sürecinden ayrılan 645 örneklik dengeli değerlendirme kümesi üzerinde ölçtük.

1 Burada accuracy, precision, recall ve F1 skorlarını kullandık.

Model seçiminde temel ölçüt olarak ise precision ve recall'u birlikte değerlendiren F1 skorunu esas aldık.

2 Sonuçlara baktığımızda modelimiz değerlendirme kümesinde yüzde 99,84 doğruluk ve yüzde 99,845 F1 skoruna ulaştı. Burada accuracy, precision, recall ve F1 skorlarını kullandık; model seçiminde temel ölçüt olarak precision ve recall'u birlikte değerlendiren F1 skorunu esas aldık.

3 Karmaşıklık matrisine baktığımızda 322 etik örneğin tamamının doğru sınıflandırıldığını görüyoruz. 323 etik dışı örneğin ise 322'si doğru sınıflandırılırken yalnızca bir örnek etik olarak tahmin edilmiş.

4 Yani bu değerlendirme kümesinde yalnızca bir yanlış negatifimiz var ve hiç yanlış pozitifimiz yok.

(Bu cümleden sonra bir saniye durun.)

10/14 Peki Gerçek Hayatta?

Ancak yüksek bir test skoru tek başına yeterli değil. Çünkü veri setimiz kontrollü bir ortamda oluşturuldu.

Bu nedenle modelin daha önce görmediği 30 örnekten oluşan ek bir stres testi gerçekleştirdik. Testte sert ama profesyonel iletişim, pasif-agresif ve iğneleyici iletişim ve nötr iş mesajlarını karşılaştırdık.

1 Model 30 örneğin 27'sini doğru sınıflandırdı.

2 Özellikle bizim için önemli olan, pasif-agresif kategorideki 10 örneğin tamamını etik dışı olarak tespit etti.

3 Bununla birlikte modelin sert ama profesyonel iletişim ile etik dışı iletişim arasındaki sınırdaki zaman zaman aşırı hassas davrandığını da gördük.

(Bu, sadece başarıyı anlatıp geçmediğimiz, dürüst bir bulgu — makale de tam olarak bu sınırlılığı belirtiyor.)

11/14 Modeli Gerçek Sisteme Dönüştürdük

Çalışmayı yalnızca bir sınıflandırma modeli olarak bırakmadık.

Modeli bir e-posta istemcisi prototipine entegre ettik. Sistem FastAPI tabanlı bir backend ile e-posta istemcisi arasında bağlantı kuruyor.

- 1 Kullanıcı gönder butonuna bastığında mesaj metin temizleme, tokenizasyon ve çıkarım adımlarından geçerek analiz ediliyor.
- 2 Etik dışı sınıfın olasılığı belirlediğimiz 0,60 eşik değerinin üzerine çıkarsa,
- 3 sistem gönderimi durduruyor ve kullanıcıya mesajını düzenlemesi için geri bildirim veriyor.

(Şimdi gerçek sistemden canlı bir demo göstereceğim — 45-60 saniye sürecek. Önce etik bir mesaj: "Toplantı notlarını müsait olduğunuzda paylaşabilir misiniz?" → gönderilebilir. Sonra etik dışı bir mesaj: "Bu raporu hâlâ göndermemiş olmanız kabul edilebilir değil..." → gönderim engellenir.)

12/14 Ne Kazandık?

Sonuç olarak bu çalışmada üç temel katkı sunduk.

- 1 İlk olarak Türkçe kurumsal iletişim bağlamına özgü bir veri seti oluşturduk.
- 2 İkinci olarak bu veri üzerinde BERTürk tabanlı bir etik dil sınıflandırma modeli geliştirdik.
- 3 Üçüncü olarak modeli gerçek kullanım senaryosuna yaklaştıran çalışan bir prototip sisteme entegre ettik.
- 4 Elbette mevcut sonuçların oluşturduğumuz veri seti ve gerçekleştirdiğimiz deneyler kapsamında değerlendirilmesi gerekiyor. Bir sonraki aşamada farklı sektörlerden gerçek dünya verileriyle veri setini genişletmek ve bağımsız veri kümeleri üzerinde doğrulama yapmak istiyoruz.

Sonu olarak bu alıřmayla amacımız yalnızca etik dıřı bir e-postayı sınıflandırmak deęil.

- 1 Kurumsal iletiřimde problemlili dilin, iletiřim gerekleřmeden nce fark edilebildięi proaktif bir yapı ortaya koymak.
- 2 Bu alıřmanın Trke kurumsal iletiřimde etik dil farkındalıęının artırılmasına katkı saęlayabileceęini dřnyoruz.
- 3 Bizi dinledięiniz iin teřekkr ederiz. Sorularınızı memnuniyetle yanıtlarız.

14/14 Modeli Deneyin

Sunum sonunda modeli kendiniz de deneyebilirsiniz — QR kodu okutarak canlı sisteme ulařabilirsiniz.